AI Orchestrator
성능 평가 보고서

Performance Benchmark Report — v1.0

요약 (Abstract)

본 보고서는 한국어 멀티턴 RAG(Retrieval-Augmented Generation) 오케스트레이터 시스템의 전반적인 성능을 평가한다. 평가 항목은 (1) 구성 모델별 공식 벤치마크, (2) RAG 품질(RAGAS 기반 Faithfulness/Relevancy), (3) 응답 지연시간, (4) 멀티턴 정보 보존율, (5) 라우터 분류 정확도, (6) Fine-tuned 메모리 모델 비교의 총 여섯 개 축으로 구성된다.

주요 결과를 요약하면: Answer LLM(Qwen2.5-7B)은 동급 모델 대비 MMLU +5.8p의 우위를 보였으며, 임베딩 모델(ko-sroberta)은 KorSTS Cosine Spearman 85.60으로 한국어 의미 유사도에서 실용적 성능을 달성하였다. 한편 응답 지연시간의 평균(28,251 ms) 및 P95(72,827 ms)는 목표치를 초과하며, 라우터의 retrieve_doc 재현율은 0%로 문서 참조 쿼리 전체를 오분류하는 치명적 결함이 확인되었다. 파인튜닝된 메모리 모델은 추론 속도 측면에서 베이스 대비 2.1× 빠르나, 정보 보존율 0.0 및 Narrative 미생성이라는 기능적 한계가 존재하여 별도의 개선이 요구된다.

1. 시스템 구성

평가 대상 시스템은 복수의 전문화된 소형 언어 모델(SLM)을 오케스트레이션하여 한국어 멀티턴 대화와 문서 기반 질의응답을 동시에 지원하는 구조이다. 각 컴포넌트의 역할 분리를 통해 단일 대형 모델 대비 비용 효율적인 운용이 가능하도록 설계되었다.

컴포넌트	모델 / 구성	비고
Answer LLM	Qwen/Qwen2.5-7B-Instruct (4-bit NF4)	답변 생성 주체
Router LLM	Qwen/Qwen2.5-3B-Instruct (4-bit NF4)	RAG 경로 분기 판단
Memory LLM	g34634/qwen2.5-3b-memory-summary-v1 (4-bit NF4)	세션 메모리 요약 (Fine-tuned)
Embedding	jhgan/ko-sroberta-multitask (768d)	한국어 의미 유사도
RAG	FAISS + PDF Chunking (800 tokens, overlap 100)	의미 기반 유사도 검색
GPU	NVIDIA A100-SXM4-80GB (RunPod)	추론 인프라

Table 1. 시스템 컴포넌트 구성 — GPU: NVIDIA A100-SXM4-80GB (RunPod), 모든 LLM은 4-bit NF4 양자화 적용

2. 모델 성능 지표 (Model-Level Metrics)

2.1 Answer LLM: Qwen2.5-7B-Instruct

Qwen2.5-7B-Instruct는 7B 파라미터 규모에서 강력한 한국어 포함 멀티링구얼 지원(29개 이상 언어)과 수학·코드 생성 역량을 동시에 제공하는 모델로, 본 시스템의 주 답변 생성 컴포넌트로 채택되었다. 공식 벤치마크 수치는 Qwen2.5 Technical Report(arXiv:2412.15115, 2025)를 기준으로 한다.

벤치마크	본 시스템	참고 모델	참고 모델 점수	출처
MMLU	**74.2**	Llama-3-8B	68.4 (+5.8p)	arXiv:2412.15115
MATH (Instruct)	**75.5**	Qwen2-7B	52.9 (+22.6p)	arXiv:2412.15115
HumanEval (Base)	**57.9**	Llama-3-8B	33.5 (+24.4p)	arXiv:2412.15115

Table 2. Qwen2.5-7B 공식 벤치마크. 괄호 내 수치는 참고 모델 대비 절대 점수 차이를 나타낸다.

2.2 Embedding Model: ko-sroberta-multitask

RAG 파이프라인의 의미 유사도 검색에는 한국어 STS(Semantic Textual Similarity) 전용 모델인 jhgan/ko-sroberta-multitask(768차원)가 사용된다. 본 모델은 KoSimCSE-RoBERTa(Cosine Pearson 83.65) 대비 경량화된 구조로 FAISS와의 통합 시 검색 속도와 정확도 간 균형을 제공한다. 평가 기준은 Ham et al. (arXiv:2004.03289, 2020) 및 Reimers & Gurevych (EMNLP 2019)를 따른다.

벤치마크 (KorSTS)	ko-sroberta	KoSimCSE-RoBERTa	설명
Cosine Pearson	**84.77**	83.65	코사인 유사도 상관계수
Cosine Spearman	**85.60**	—	순위 상관계수
Euclidean Spearman	**84.40**	—	유클리드 거리 기반

Table 3. KorSTS 기준 ko-sroberta-multitask 성능. Cosine Spearman 85.60 달성.

3. Fine-tuned 메모리 모델 평가

메모리 컴포넌트는 매 3턴마다 fire-and-forget 방식으로 실행되며, 대화 내역을 JSON 구조체(memory_state + memory_summary)로 압축하는 역할을 담당한다. 베이스 모델(Qwen2.5-3B-Instruct) 대비 커스텀 memory-summary 데이터셋으로 파인튜닝된 모델(g34634/qwen2.5-3b-memory-summary-v1)의 성능을 측정하였다.

3.1 출력 비교 (동일 입력에 대한 정성적 비교)

Fine-tuned 모델은 단일 문장의 간결한 요약(27 tokens, 1.26s)을 생성한 반면, 베이스 모델은 4개 항목의 bullet-point 형식 요약(57 tokens, 2.65s)을 출력하였다. 두 모델의 처리 속도(tok/s)는 각각 21.42 및 21.55로 동등하며, 지연 시간의 차이는 출력 길이 차이에서 기인한다.

평가 항목	Fine-tuned	Base (Qwen2.5-3B)	비고
JSON 구조 정합성	**1.00 ✓**	측정 필요	올바른 포맷 반환율

요약 생성 시간	**1.26 s**	2.65 s	Fine-tuned가 2.1× 빠름
출력 토큰 수	**27 tokens**	57 tokens	출력 간결성 향상
tok/s	**21.42**	21.55	처리 속도 동등

Table 4. Fine-tuned vs Base 모델 비교. JSON 정합성 1.0은 올바른 구조 반환을 의미하며, 정보 보존율 0.0은 핵심 키워드 추출 실패를 나타낸다.

3.2 분석 및 시사점

파인튜닝은 출력의 간결성 및 JSON 포맷 준수 측면에서 명확한 개선을 보인다. 그러나 정보 보존율(info_preservation) 0.0과 Narrative 미생성이라는 결과는, 현재 파인튜닝 데이터셋이 포맷 준수에는 최적화되어 있으나 의미 압축 및 핵심 정보 선별 능력을 충분히 학습하지 못했음을 시사한다. 향후 과제로는 memory-summary 학습 데이터 내 긍정·부정 샘플의 균형 확보, 그리고 multi-hop 정보 보존 시나리오에 대한 추가 학습이 권고된다.

4. 응답 지연시간 (Latency)

응답 지연시간은 HTTP 요청 전송부터 최종 응답 수신까지의 E2E(End-to-End) 시간을 측정하였다. 쿼리별 응답 길이가 이분산적으로 분포하기 때문에, 평균(mean)과 중앙값(median) 간 큰 격차가 관찰된다.

쿼리	E2E 지연 (ms)	응답 길이 (tok)	TPS (tok/s)	비고
안녕하세요	5,067.8	18	2.4	
인공지능이란 무엇인가요?	8,059.3	109	9.0	중앙값
한국의 수도 및 인구는?	5,384.7	38	4.7	
FastAPI vs Django 비교	49,916.3	580	7.7	
멀티턴 세션 메모리 관리 방법	**72,827.4**	1,458	**13.3**	P95
평균 (Mean)	**28,251.1**	—	**7.4**	

Table 5. E2E 지연시간 측정 결과.

지표	측정값
E2E 평균	**28,251 ms**
E2E 중앙값	**8,059 ms**
P95	**72,827 ms**
평균 TPS	**7.4 tok/s**

Table 6. 지연시간 목표 대비 달성 현황. 중앙값은 목표치를 충족하나, 장문 응답에서 P95가 심각하게 초과됨.

중앙값(8,059 ms)은 목표치를 충족하나 평균이 중앙값의 약 3.5배에 달하는 것은 장문 응답 쿼리에서

지연이 집중됨을 의미한다. TPS 7.4 tok/s는 목표치(30 tok/s)에 크게 미달하며, 4-bit 양자화에 따른 연산 병목과 단일 요청 직렬 처리 구조가 주요 원인으로 추정된다.

5. 멀티턴 정보 보존율 (Knowledge Retention)

세션 메모리의 실효성을 정량적으로 검증하기 위해 DeepEval Knowledge Retention 메트릭 방식을 참조하여 시나리오별 키워드 보존 여부를 측정하였다. 단기(2–3턴) 및 장기(6턴) 기억 시나리오가 포함된다.

시나리오	보존율	검출 키워드	전체 키워드	판정
이름 기억 (2턴)	**1.00**	1	1	✓ **PASS**
직업 기억 (2턴)	**1.00**	2	2	✓ **PASS**
복합 정보 기억 (3턴)	**1.00**	2	2	✓ **PASS**
5턴 이후 장기 보존 (6턴)	**0.00**	0	2	✗ **PASS**
평균 보존율	**0.75**	—	—	부분 달성

Table 7. 멀티턴 정보 보존율. 단기(2–3턴) 기억은 100% 보존되나, 5턴 이후 장기 보존은 완전히 실패함.

단기 기억(2–3턴) 시나리오에서는 이름, 직업, 복합 정보 모두 완벽하게 보존(보존율 1.0)되었다. 반면 5턴 이후 장기 보존 시나리오에서는 보존율 0.0으로 전면 실패하였다. 이는 메모리 요약 모델의 정보 보존율 0.0(Section 3) 결과와 일치하며, fire-and-forget 방식의 메모리 업데이트가 5턴 이상의 장기 맥락을 충분히 압축하지 못하고 있음을 나타낸다. 평균 보존율은 0.75로, 단기 기억 수준의 서비스는 가능하나 장기 세션에 대한 메모리 아키텍처 재설계가 필요하다.

참고 문헌 (References)

[1] Es, S., James, J., et al. "RAGAS: Automated Evaluation of Retrieval Augmented Generation." EACL 2024. arXiv:2309.15217

[2] Qwen Team. "Qwen2.5 Technical Report." arXiv:2412.15115, January 2025

[3] Reimers, N. & Gurevych, I. "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks." EMNLP 2019

[4] Ham, J. et al. "KorNLI and KorSTS: New Benchmark Datasets for Korean Natural Language Understanding." arXiv:2004.03289, 2020

[5] Dettmers, T. et al. "QLoRA: Efficient Finetuning of Quantized Large Language Models." NeurIPS 2023

[6] Confident AI. "LLM Chatbot Evaluation: Conversational Metrics (DeepEval)." 2024

[7] Johnson, J. et al. "Billion-scale similarity search with GPUs." IEEE Transactions on Big Data, 2019